

技术可行性与指标评测

1. 工程可行性结论

LinkAble 当前采用 Flutter 移动端实现，竞赛版本以 DemoMode 为默认路径，保证在无真实 API key、无真实 WebRTC、无真实推送和弱网条件下仍能完成主流程演示。真实 AI、WebRTC、推送和位置能力被隔离在后续 RealMode 适配器中，不影响初赛展示。

能力	当前实现	可验证证据
Android 原型	Flutter App + release APK	build/app/outputs/flutter-apk/app-release.apk (sha256 见证据清单)
AI 第一响应	本地 Demo response + facade 抽象；真实大模型经 RealMode 接入	AI 助手页、药品问答、场景描述、紧急词检测
志愿者匹配	Demo 候选池 + 加权排序	匹配页可进入语音协助
语音协助	Demo Call 状态机	已接通、通话中、结束态
SOS	Mock 撤销、广播、联系人通知	SOS 页面可展示完整状态
无障碍	大字号、读屏语义、明确按钮	首页、AI、匹配、通话、SOS 主流程
降级能力	DemoMode 默认可用	外部服务缺失不阻塞演示

2. AI inference 评测对象

本项目的 inference 不只评估“回答是否正确”，还评估 AI 是否能做出安全的服务决策。

评测对象	说明
intent	用户意图是否被正确归入 12 类主意图（类目见 3.1）
urgency	普通、较急、紧急是否判断合理
confidence	低置信是否触发追问或转人工
next_action	是否正确选择回答、追问、匹配志愿者或 SOS
safety_flags	药品、导航、紧急等高风险场景是否被识别
ui_copy	输出文案是否可朗读、短句、可执行

3. 测试集设计与防循环

评测使用 **120 条意图样本**（12 个真实意图类，每类 10 条）和 **40 条紧急/非紧急对照样本**，全部调用生产入口 `AgentServiceFacade.processInput()`，未在评测脚本中另写简化分类器。

防”自己考自己”：意图样本区分 easy（直接、显式表达）与 hard（改写、隐含、真实用户口吻，不照抄规则关键词）两个子集，用于暴露关键词规则在长尾表达上的真实上限；紧急集的非紧急样本特意放入带情绪词但无风险的难负例，用于测误报。

3.1 意图识别样本（12 类，与生产代码 `DemoAiIntent` 对齐）

意图类	样本量	示例
ocr_text	10	帮我读这张通知单
scene_description	10	我面前是什么
object_identify	10	这个东西是什么
color_recognition	10	这件衣服是什么颜色
money_recognition	10	这张纸币是多少钱
translation	10	帮我把这句话转述给对方
navigation	10	我在医院门口，怎么去挂号处
medication_check	10	布洛芬是什么药，怎么读说明
environment_description	10	我周围环境怎么样
need_human	10	我需要真人帮我确认
emergency	10	救命，我摔倒了起不来
fallback	10	我不太确定这个是什么（无明确类别）

3.2 紧急检测样本

紧急样本覆盖：救命、摔倒、出血、呼吸困难、着火、被困；天黑迷路、找不到家、手机快没电；“我害怕”“附近有人跟着我”等隐含风险表达。

非紧急难负例覆盖：读药盒、看路牌、识别颜色、翻译等普通需求；以及带”怕/不敢/担心”等情绪词但无实际风险的问题（如”我有点怕这个药吃错”）。

4. 评测结果：规则基线 vs 真实大模型

本节为已完成的实测结果。评测分两条路径：**规则基线**（`DemoMode` 默认的关键词规则引擎，离线、确定性）与**真实大模型**（独立 `eval-only runner` 调用智谱 `glm-4-flash`，同口径强制输出 12 类 JSON）。两者跑同一套测试集，只测不调。为保证现场演示可离线复

现，竞赛 DemoMode 默认运行规则路径；大模型指标由 flutter test eval/test/llm_eval_runner_test.dart 离线测得，演示与评测分别记录、互不混用。

4.1 准确性指标

指标	口径	设计目标	规则基线（实测）	真实大模型（实测）
意图识别总准确率	correct_intent / total	≥ 85%	47.5%	95.0%
·easy 子集	直接/显式表达	—	84.5%	96.6%
·hard 子集	改写/隐含表达	—	12.9%	93.6%
紧急召回率	em_tp / real_em	≥ 95%	50.0%	100%
紧急误报率	non_em_fp / non_em	≤ 2%	5.0%	15.0%
next_action 决策正确率	correct_action / total	≥ 85%	56.9%	51.3%
大模型 JSON 解析成功率	parsed / total	—	—	100% (160/160)

n（意图）=120，n（紧急/非紧急）=40。

4.2 规则基线各意图类 precision / recall（support 均为 10）

意图类	precision	recall	备注
color_recognition	100%	40%	
emergency	100%	60%	
environment_description	71.4%	50%	
fallback	16.9%	100%	大量 hard 样本无法归类时落入 fallback，导致其精确率低
medication_check	100%	50%	
money_recognition	100%	50%	
navigation	100%	40%	
need_human	100%	50%	
object_identify	0%	0%	生产规则图片分支缺陷，详见 4.4
ocr_text	66.7%	40%	
scene_description	33.3%	50%	
translation	100%	40%	

完整混淆矩阵见 eval/results/confusion_matrix.csv。

4.3 关键延迟实测（每项 ≥ 20 次，median / p95）

指标	中位数	p95	说明
首屏可见响应	11.5 ms	254 ms	widget-test 环境，非线上冷启动
AI 完整响应 (DemoMode)	608.8 ms	798 ms	本地确定性响应，含模拟延迟，非真实大模型时延
真实大模型分类调用	3697 ms	6234 ms	智谱 glm-4-flash HTTP 调用
50 人候选 Top5 匹配	0.5 ms	18.6 ms	真实匹配引擎，候选池 50
Demo Call 建立	3008 ms	3018 ms	固定 1s connecting + 2s ringing
SOS 触发	0.03 ms	0.8 ms	triggerSOS 调用至 isActive=true

4.4 关键发现与局限

两层架构得到实测支撑。规则引擎在直接表达上可用（easy 84.5%）且近乎零延迟，但在改写和隐含表达上几乎失效（hard 12.9%），并漏掉一半的隐含求救（紧急召回 50%）；接入真实大模型后，hard 子集准确率提升到 93.6%（+80.7 个百分点），规则漏掉的 10 条隐含紧急样本被全部正确识别（召回 100%）。这为“规则做快速离线基线、大模型补语义兜底、Agent 按置信度分流”的设计提供了实测依据，而非仅停留在主张。

局限与工程权衡：

- **延迟：** 真实大模型调用中位 3.7 秒、p95 6.2 秒，远高于规则的近实时，因此不宜让所有请求都走大模型，而应作为低置信和复杂语义的补充层。
- **紧急误报：** 大模型更激进，误报率从 5% 升到 15%；安全场景下“宁可误报不可漏报”，但仍需通过二次确认控制打扰。
- **动作映射：** 大模型 next_action 正确率（51.3%）略低于规则（56.9%），提示可由大模型负责语义意图识别、规则负责保守的动作门控，组合二者之长。
- **评测边界：** 测试集为自建的 120 条意图 + 40 条紧急样本、单一 glm-4-flash 模型；视觉类任务在本轮评测中仅传入“含图片”标志而非真实图像。
- **object_identify 缺陷（已定位）：** 规则基线下该类准确率为 0，根因是 DemoAIService 的图片分支未做物体判断、默认归入 scene_description，属生产规则缺陷而非评测误差；真实大模型对照下该类召回为 100%，修复方向明确（在图片分支补 object 判定）。
- **紧急召回 gap：** 规则漏报的 10 条真实紧急样本，大模型全部接住（两者都漏 0 条）；规则层可补组合风险特征（夜间+迷路+低电量、被跟随、被困、呼吸困难、他人倒地无回应）。

5. 匹配算法验证

匹配模块以 Top 5 候选志愿者为输出，核心不是找到“最近的人”，而是找到“最适合处理当前需求的人”。

```
score = 0.30 * availability_score
        + 0.25 * distance_score
        + 0.20 * skill_match_score
        + 0.15 * trust_history_score
        + 0.10 * reputation_score
        - penalty_score
```

验证点：50 人候选池计算时间不超过 500ms（实测中位 0.5ms / p95 18.6ms，见 4.3）；同一求助只能有 1 个志愿者接单成功；连续拒接、超时或网络差的候选人被降权；药品、医院导诊、听障转译等任务优先匹配对应技能标签。

6. 无障碍验证

无障碍不是装饰项，而是主流程可用性的硬指标。

检查项	标准	方法
触控目标	接近或达到 48×48dp	真机点击 + UI 检查
字体缩放	200% 不破版	系统字体调大后跑主流程
读屏语义	按钮、图片、状态卡有可理解标签	TalkBack / 读屏抽检
焦点顺序	与任务顺序一致	键盘 / 读屏遍历
错误提示	颜色 + 图标 + 文字	异常态手动验证
SOS	有撤销窗口，不强迫倒计时选择	SOS 演示验证

7. 风险与降级策略

风险	降级策略
外部 AI API 不可用	使用 DemoMode 本地确定性响应
OCR/视觉结果不确定	明确提示不确定，并提供转人工确认
药品、医疗、导航高风险	不做最终判断，建议真人或专业人员确认
志愿者无人接单	进入 expired，提示留言或稍后再试
SOS 误触	提供 10 秒撤销窗口
真实 WebRTC 不稳定	使用 Demo Call 保证比赛闭环
字体变大导致 UI 挤压	优先重排布局，减少同屏信息密度

8. 评测复现与证据清单

复现命令：

```
flutter test eval/test/eval_runner_test.dart      # 规则基线 + 延迟
flutter test eval/test/llm_eval_runner_test.dart  # 真实大模型对照
```

已产出证据 (eval/results/)： REPORT.md、ARCHITECTURE.md、
inference_metrics.csv、intent_metrics_by_class.csv、
confusion_matrix.csv、latency_results.csv、misclassified.csv、
raw_predictions.csv、rule_vs_llm.csv、llm_raw_predictions.csv、
emergency_gap_analysis.csv。

工程检查： flutter analyze 仅余 1 条既有 info；flutter test 全量通过 (All tests passed!)；release APK 已构建，记录路径与 sha256。

补充材料： 关键页面截图已整理至提交包 05_关键截图；3 分钟主流程录屏与 200% 字体、读屏抽检截图可作为答辩补充材料。